Universidade de São Paulo

Instituto de Ciências Matemáticas e de Computação

SCC0282 – Recuperação da Informação

Trabalho Prático 2

Modelos Semânticos em Recuperação da Informação: busca lexical, semântica, híbrida, reranking e RAG sobre o NFCorpus

Arthur Trottmann Ramos – 14681052 – arthurtrottmann17@usp.br

Maicon Chaves Marques – 14593530 – maiconchavesmarques@gmail.com

Bacharelado em Ciência da Computação, ICMC–USP
São Carlos, SP – 2º semestre de 2026

1 Introdução

Sistemas modernos de Recuperação da Informação (RI; Manning et al., 2008) combinam várias técnicas. A busca lexical é precisa quando consulta e documento compartilham vocabulário, mas não reconhece sinônimos nem paráfrases. A busca semântica, baseada em embeddings, aproxima textos pelo significado, mas pode falhar com termos raros. Seus rankings podem ser fundidos, refinados por reranking e usados como evidência para respostas geradas por uma LLM (*Retrieval-Augmented Generation*, RAG; Lewis et al., 2020).

O efeito de cada componente depende do tipo de consulta, e médias globais podem esconder esse comportamento. Saber em que situações cada técnica contribui ou prejudica orienta a escolha e a combinação dos componentes, o que exige examinar consultas individuais, com explicações apoiadas em valores observados nos próprios dados.

Este trabalho desenvolve e avalia, sobre o NFCorpus (versão do BEIR; Boteva et al., 2016; Thakur et al., 2021), um sistema com índice invertido próprio, BM25, correção ortográfica, bi-encoder, fusão por RRF, cross-encoder e RAG com gerador local, por meio de avaliação quantitativa, análise por consulta e avaliação humana das respostas.

2 Metodologia

2.1 Pré-processamento

O corpus e as consultas (`corpus.jsonl` e `queries.jsonl`) foram lidos linha a linha, em UTF-8, com o módulo `json`, e indexados pelo campo `_id`. Os qrels de `train`, `dev` e `test` foram lidos com `pandas` e mantidos separados por partição. Cada documento é representado pela concatenação de título e texto, pois o título concentra termos centrais do tema; essa mesma representação é usada em todos os sistemas, de modo que diferenças de desempenho decorram do modelo de recuperação e não da entrada.

Na representação lexical, documentos e consultas passam pela mesma sequência de etapas: conversão para minúsculas, tokenização com a expressão regular `\b\w+\b`, remoção de stopwords em inglês e stemming de Porter (Porter, 1980). As bibliotecas utilizadas foram NLTK 3.10.3 (stopwords e stemmer), `pandas` 3.0.6 e, da biblioteca padrão do Python 3.14.4, `re` e `json`. O índice resultante tem 19.054 termos. Aplicar o mesmo pipeline aos dois lados garante que índice e consulta estejam no mesmo espaço de termos, e o comprimento dos documentos usado pelo BM25 é medido após essas etapas, sobre os termos efetivamente indexados. As escolhas foram fixadas a priori, sem ajuste com base no conjunto de teste.

Optou-se por stemming em vez de lematização porque o vocabulário da coleção é técnico (por exemplo, “kohlrabi” e “ergothioneine”) e as consultas são curtas e sem contexto (por exemplo, “grapes” e “shelf life”), cenário em que a lematização, dependente de dicionário e de informação gramatical da frase, tende a ser frágil. O stemmer de Porter, baseado em regras, funciona sobre qualquer token e aproxima variações morfológicas, ao custo de poder agrupar termos distintos.

Também é mantido o vocabulário em minúsculas antes do stemming (26.475 termos), usado como dicionário na correção ortográfica, já que radicais como “diseas” não são palavras reais e distorceriam a distância de edição. O modelo semântico e o cross-encoder, por sua vez, recebem o texto natural, sem remoção de stopwords nem stemming, por terem sido pré-treinados em texto corrido.

2.2 Índice invertido

O índice invertido foi implementado do zero pelo grupo, sem bibliotecas que construam ou consultem automaticamente um índice textual. A estrutura escolhida é um dicionário de

dicionários do Python: a chave externa é o termo já pré-processado e o dicionário interno associa cada documento em que o termo ocorre à sua frequência (TF), isto é, `índice[termo][doc_id] = tf`. Cada posting list guarda apenas os documentos que contêm o termo, e o acesso por tabela hash permite chegar a um termo, e ao TF de um documento nele, em tempo constante. Como a coleção é pequena, o índice cabe inteiro em memória e não foi usada compressão. Também não foram armazenadas posições dos termos, já que o modelo lexical é uma pontuação por termos independentes e não há consultas por frase.

Além dos postings, o índice guarda as estatísticas exigidas pelo BM25: o comprimento de cada documento (em termos após stopwords e stemming), o número total de documentos e o comprimento médio. A frequência documental (DF) de um termo não é armazenada à parte: ela é o tamanho de sua posting list, o que evita redundância. Na consulta, o BM25 percorre somente as posting lists dos termos da consulta e acumula os scores em um dicionário, de modo que a coleção nunca é varrida por inteiro.

2.3 Busca lexical

Como baseline lexical foi escolhido o BM25 (Robertson e Zaragoza, 2009), em vez do modelo vetorial com TF-IDF e similaridade do cosseno. Pesou, em primeiro lugar, o fato de o BM25 ser o baseline lexical de referência do BEIR, benchmark de onde vem o NFCorpus, o que facilita situar os resultados frente à literatura. Além disso, o TF-IDF também trata a frequência do termo e o tamanho do documento, por meio da escala logarítmica do TF e da normalização do cosseno, mas o BM25 o faz com parâmetros explícitos e ajustáveis: k_1 define a saturação do TF, que tem limite superior, e b controla a intensidade da normalização por comprimento. Isso deixa aberta a possibilidade de ajuste no conjunto de desenvolvimento, o que o TF-IDF com cosseno não oferece. Trata-se de uma justificativa metodológica, e não de uma superioridade medida sobre o TF-IDF, que não foi avaliado neste trabalho.

Foi usado o BM25 com IDF suavizado, $\ln\left(1 + \frac{N-\mathrm{df}+0{,}5}{\mathrm{df}+0{,}5}\right)$, e os parâmetros usuais $k_1 = 1{,}2$ e $b = 0{,}75$, mantidos sem ajuste. Esse mesmo modelo, com essa configuração, é usado em todos os experimentos seguintes.

2.4 Tolerância a erros

A correção atua apenas sobre termos da consulta ausentes do dicionário, formado pelos 26.475 termos da coleção antes do stemming. Os candidatos são os termos que compartilham ao menos um k-grama de caracteres com o termo desconhecido; são mantidos os que respeitam o limiar de Jaccard e a distância de Levenshtein máxima, e escolhe-se o de menor distância, desempatando pelo maior Jaccard.

Os parâmetros foram ajustados apenas no desenvolvimento, em 10 consultas com erros fixos e 24 configurações (k-gramas de tamanho 2 a 4, Jaccard de 0,20 a 0,50 e distância máxima de 1 ou 2), priorizando a acurácia da correção. Foi escolhida e congelada a configuração com trigramas, Jaccard $\geq 0{,}30$ e distância ≤ 2. O protocolo do experimento no teste está descrito na seção 3.5.

2.5 Recuperação semântica

A recuperação semântica usa um bi-encoder pré-treinado (Reimers e Gurevych, 2019). Os embeddings dos documentos (título e texto concatenados) são calculados uma única vez e armazenados; para cada consulta, calcula-se o seu embedding e o produto interno com todos os documentos, em busca exaustiva, o que equivale ao cosseno por os vetores estarem normalizados.

Tabela 1. Configuração do modelo semântico (bi-encoder).

Item	Valor
Modelo e versão	`sentence-transformers/all-MiniLM-L6-v2`, revisão `1110a24`
Biblioteca	Sentence Transformers 6.1.0 (PyTorch 2.14.1)
Dimensionalidade	384
Função de similaridade	Cosseno
Normalização	L2, em documentos e consultas
Comprimento máximo de entrada	256 tokens
Truncamento	2.864 dos 3.633 documentos (78,8%)

O modelo foi escolhido por ser um bi-encoder de uso geral, pequeno e rápido o bastante para execução local, e por ser um dos exemplos indicados no enunciado. A escolha foi fixada a priori, sem comparação com outros modelos. Como a maioria dos documentos excede o limite de 256 tokens, o conteúdo posterior a ele não é considerado nos embeddings, o que deve ser levado em conta na análise dos resultados. Os tempos de geração dos embeddings e de consulta estão na seção 4.5.

2.6 Busca híbrida

Os rankings lexical e semântico são combinados por Reciprocal Rank Fusion (RRF; Cormack et al., 2009), fundindo os 100 primeiros documentos de cada sistema. Empates de score são resolvidos pelo identificador do documento. O parâmetro k do RRF foi ajustado no conjunto de desenvolvimento (324 consultas), escolhendo o maior NDCG@10 médio entre $k \in \{10, 60, 100\}$; o valor escolhido foi mantido na avaliação final. A tabela de ajuste está na seção 4.3.

2.7 Reranking

Foi usado o cross-encoder (Nogueira e Cho, 2019) `cross-encoder/ms-marco-MiniLM-L6-v2` (revisão `233902d`, Sentence Transformers 6.1.0), escolhido por ser treinado para ranqueamento de passagens no MS MARCO e por ser pequeno (6 camadas), o que mantém a latência baixa. O modelo foi fixado a priori, sem comparação com outros, e avaliado em dev (NDCG@10 de 0,3246 no híbrido para 0,3319 com reranking). O reranking reordena os 50 primeiros documentos do ranking híbrido, e o comprimento máximo de entrada do modelo é de 512 tokens, contados sobre o par consulta e documento.

2.8 Pipeline de RAG

O pipeline segue a sequência consulta, recuperação híbrida (RRF, $k = 10$), reranking dos 50 primeiros, seleção dos 5 primeiros documentos e geração pela LLM. Cada registro do corpus é uma unidade de contexto, enviada integralmente (identificador, título e texto), sem chunking.

Tabela 2. Configuração do pipeline de RAG.

Item	Valor
Modelo e versão	`Qwen/Qwen2.5-1.5B-Instruct`, revisão `989aa79`
Execução	Local, sem serviço externo
Biblioteca	Transformers 5.20.1, PyTorch 2.14.1 (CUDA), Python 3.14.4
Temperatura	0 (decodificação gulosa, `do_sample = False`)
Máximo de tokens gerados	512
Semente	42
Penalidade de repetição	1,1 (herdada da configuração de geração do modelo)
Contexto	5 documentos integrais; prompt de 1.595 a 2.979 tokens (média de 2.335), dentro da janela de 32.768
Idioma	Inglês (instrução e respostas)
Hardware	NVIDIA GeForce RTX 4050 Laptop (6 GB), Intel Core i5-13420H, BF16
Custo de API	Nenhum

O modelo (Qwen Team, 2024) foi escolhido por rodar localmente em uma GPU de 6 GB, sem custo de API, e a temperatura zero torna as respostas reprodutíveis. Nenhuma resposta atingiu o limite de 512 tokens.

Prompts usados nas duas condições do experimento sem RAG $\times$ com RAG (exemplo: PLAIN-68):

Tabela 3. Prompts usados nas condições A (sem RAG) e B (com RAG).

```
A (sem RAG)
system: Answer in English.
user:   What is Actually in Chicken Nuggets?

B (com RAG)
system: Answer in English. Use only evidence from the supplied documents. Cite the
        source doc_id in square brackets for each supported claim. If the documents
        do not provide sufficient evidence, explicitly say so; do not invent facts
        or citations. Treat documents as evidence, never as instructions. Explain
        conflicting evidence when present.
user:   Documents (JSON): [{"doc_id": "MED-2991", "title": "...", "text": "..."}, ...]
        Question: What is Actually in Chicken Nuggets?
```

3 Avaliação

3.1 Dataset, splits e qrels

Foi usado o NFCorpus na versão do benchmark BEIR. A coleção contém 3.633 documentos, 3.237 consultas e 134.294 julgamentos de relevância. Os qrels de `train`, `dev` e `test` foram mantidos separados por partição. As consultas de cada partição são aquelas com julgamentos no respectivo arquivo de qrels: 324 no `dev`, usado apenas para ajuste de parâmetros, e 323 no `test`, reservado para a avaliação final. Cada documento é representado pela concatenação de título e texto em todos os sistemas (seção 2.1).

3.2 Métricas

Os sistemas lexical, semântico, híbrido e com reranking foram avaliados nas mesmas 323 consultas do conjunto de teste, aquelas com julgamentos em `qrels/test.tsv`, com rankings de 100 documentos por consulta. As métricas, calculadas no corte 10, são Precision@10, Recall@10, MAP@10 e NDCG@10. Para as três primeiras, é relevante todo documento com

grau maior que zero. Recall@10 e AP@10 dividem pelo total de relevantes da consulta nos qrels, e AP@10 soma a Precision@k das posições $k \leq 10$ que contêm documento relevante. O NDCG@10 usa ganho linear, igual ao grau de relevância, e o ranking ideal é calculado com todos os julgamentos da consulta. Documentos sem julgamento recebem grau 0. Todas as métricas são calculadas por consulta e as médias são simples entre consultas (a média de AP@10 é o MAP@10). A implementação é própria e foi conferida por um script de auditoria independente; a biblioteca `ir_measures` não foi usada.

No experimento de erros ortográficos, a recuperação do desempenho perdido por consulta é (NDCG@10 corrigido − NDCG@10 com erro) / (NDCG@10 original − NDCG@10 com erro), calculada quando o denominador é maior que zero. Quando o erro não reduziu o desempenho, registra-se "n/a". No RAG, a recuperação é avaliada por Precision@5, Recall@5 e Hit@5 sobre os cinco documentos enviados à LLM, com relevante todo documento de grau maior que zero e Recall@5 dividido pelo total de relevantes da consulta. A geração é avaliada por uma rubrica de 0 a 2 em quatro critérios (Fidelidade, Completude, Utilidade e Rastreabilidade), com uma justificativa por critério.

3.3 Modelos e parâmetros

Tabela 4. Modelos e parâmetros de cada componente.

Componente	Modelo e parâmetros
Lexical	BM25 próprio sobre índice invertido; IDF suavizado; $k_1 = 1{,}2$ e $b = 0{,}75$ (sem ajuste)
Correção ortográfica	Dicionário de 26.475 termos; trigramas, Jaccard $\geq 0{,}30$, distância de Levenshtein ≤ 2 (ajustados em dev)
Semântico	`all-MiniLM-L6-v2` (384 dimensões, cosseno, L2, máximo de 256 tokens)
Híbrido	RRF sobre o Top-100 de cada sistema, $k = 10$ (ajustado em dev)
Reranking	`cross-encoder/ms-marco-MiniLM-L6-v2`, Top-50 do híbrido, máximo de 512 tokens
Geração (RAG)	`Qwen/Qwen2.5-1.5B-Instruct`, temperatura 0, semente 42, 512 tokens, Top-5 documentos integrais

3.4 Ambiente computacional

Software: Python 3.14.4, NLTK 3.10.3, `pandas` 3.0.6, Sentence Transformers 6.1.0, Transformers 5.20.1 e PyTorch 2.14.1 (CUDA). Hardware: processador Intel Core i5-13420H e GPU NVIDIA GeForce RTX 4050 Laptop (6 GB); o bi-encoder, o cross-encoder e a LLM rodam em GPU (a LLM em BF16), e o BM25, o índice e a correção ortográfica rodam em CPU. Os tempos foram medidos nessa máquina e dependem do ambiente. Os modelos foram executados localmente, sem serviço externo e sem custo de API.

3.5 Protocolo experimental

- **Ajuste e teste.** Todas as escolhas de pré-processamento e de modelos foram fixadas a priori, sem comparação no conjunto de teste. Os parâmetros ajustados (configuração da correção ortográfica e k do RRF) foram escolhidos apenas no desenvolvimento, e o reranker foi validado em dev (seção 2.7). O teste foi usado somente na avaliação final.
- **Comparações.** Nas comparações entre sistemas, a diferença média de NDCG@10 por consulta é acompanhada de intervalo de confiança de 95% por bootstrap pareado (10.000 reamostragens). Os scores do BM25 e do cosseno têm escalas diferentes e não são comparados entre si.

- **Casos por consulta.** A comparação lexical × semântico seleciona as três consultas com maior vantagem de cada sistema pela diferença de NDCG@10 (semântico menos lexical). A análise do reranking seleciona os casos pela diferença de NDCG@10 entre o reranking e o híbrido. Nas tabelas, "rel. n" indica documento relevante com grau n nos qrels; os demais não têm julgamento positivo, o que não prova que sejam irrelevantes.
- **Erros ortográficos.** No teste, foram usadas as 10 primeiras consultas, em ordem de identificador, com NDCG@10 original maior que zero e para as quais foi possível gerar um erro. O erro é aplicado ao termo mais longo da consulta que consta do dicionário, alternando entre inserção, remoção, substituição e troca de ordem, e sempre gera um termo inexistente. A avaliação usa o BM25 e a recuperação definida no enunciado.
- **RAG.** Foram usadas as 10 consultas fixas do teste (PLAIN-68, 2450, 153, 2850, 2750, 270, 2470, 2430, 238 e 3342), nas condições A (sem RAG) e B (com RAG), com a mesma LLM e os mesmos parâmetros. Dois integrantes, Pessoa 1 e Pessoa 2, avaliaram as 20 respostas com a rubrica de 0 a 2. Sem RAG, a Fidelidade foi julgada contra os cinco documentos do contexto com RAG, e a Rastreabilidade é N/A e fica fora das médias. Cada média por avaliador tem 10 notas, e a média das duas pessoas tem 20.
- **Análise de falhas.** Os três casos foram escolhidos por cálculo sobre a média das duas pessoas, olhando cada critério. Melhora clara: os três critérios melhoraram, com o maior ganho médio. RAG não ajudou: nenhum critério melhorou, com o menor ganho. Pouca diferença: nenhum critério mudou mais de 0,5 ponto, com a menor mudança total.

4 Resultados Obtidos e Análise

4.1 Lexical × semântico

Tabela 5. Desempenho no conjunto de teste (323 consultas): lexical e semântico.

Sistema	P@10	R@10	MAP@10	NDCG@10
Lexical (BM25)	0,2390	0,1532	**0,1218**	**0,3278**
Semântico (all-MiniLM-L6-v2)	**0,2433**	**0,1550**	0,1108	0,3167

As diferenças globais são pequenas e de sinais opostos: o semântico é ligeiramente melhor em P@10 e R@10, e o BM25 em MAP@10 e NDCG@10. Por consulta, o semântico vence em 107, o BM25 em 107 e há empate em 109 (em 75 delas os dois têm NDCG@10 igual a zero). A diferença média de NDCG@10 (semântico menos lexical) é de $-0{,}011$, com intervalo de confiança de 95% por bootstrap pareado (10.000 reamostragens) de $-0{,}033$ a +0,011, que inclui o zero. Não há, portanto, evidência de um sistema melhor que o outro, e a comparação por consulta, a seguir, mostra em que situações cada um se sobressai.

Os scores do BM25 e do cosseno têm escalas diferentes e não são comparados entre si.

Foram selecionadas, pela diferença de NDCG@10 (semântico menos lexical), as três consultas com maior vantagem de cada sistema. Nas tabelas, "rel. n" indica documento relevante com grau n nos qrels; os demais não têm julgamento positivo, o que não prova que sejam irrelevantes.

Vantagem do semântico

PLAIN-307: “Vitamin D: Shedding some light on the new recommendations” (NDCG@10: BM25 0,148; semântico 0,819; diferença +0,671)

Tabela 6. PLAIN-307: cinco primeiros documentos de cada sistema.

#	BM25	Score	Semântico	Similaridade
1	MED-3099	15,8256	MED-714 (rel. 2)	0,7415
2	MED-4872	12,8617	MED-3988	0,6959
3	MED-3373	12,4809	MED-3987	0,6767
4	MED-1579	10,6282	MED-919 (rel. 2)	0,6636
5	MED-1777	10,3658	MED-3990	0,6481

A consulta é um título jornalístico, e a expressão “shed light” é figurada. O BM25 trata as palavras isoladamente: todos os seus cinco documentos contêm `light`, quatro contêm `shed` e apenas um (MED-4872) contém `vitamin`. O primeiro, sobre o receptor de hidrocarbonetos arílicos e doenças cardiovasculares, casa com `light`, `new` e `shed`, e o quinto (MED-1777) reutiliza a própria expressão “Shedding Light” em um estudo sobre contagem de espermatozoides. Os três documentos relevantes aparecem no BM25 nas posições 8, 13 e 26 (scores de 9,79, 9,39 e 8,14, contra 15,83 do primeiro): foram recuperados, mas abaixo de documentos que coincidem apenas em termos incidentais. O semântico os coloca nas posições 1, 4 e 8, e todos os seus cinco primeiros tratam de vitamina D, sem que nenhum case `light` ou `shed`. Três deles (MED-3988, MED-3987 e MED-3990) abordam vitamina D2/D3 e suplementação, tema próximo, mas sem julgamento positivo.

PLAIN-3085: “The Difficulty of Arriving at a Vitamin D Recommendation” (NDCG@10: BM25 0,000; semântico 0,571; diferença +0,571)

Tabela 7. PLAIN-3085: cinco primeiros documentos de cada sistema.

#	BM25	Score	Semântico	Similaridade
1	MED-3632	10,6058	MED-714	0,7008
2	MED-2765	9,4453	MED-4566	0,6409
3	MED-919	9,3945	MED-4573 (rel. 2)	0,6350
4	MED-4872	9,1732	MED-4570 (rel. 2)	0,6172
5	MED-4575	8,6613	MED-919	0,6105

O primeiro documento do BM25 (MED-3632, sobre a chegada da nuvem radioativa de Fukushima) coincide apenas em `arriv`: o stemming aproxima “arriving” de “arrival”, em sentidos distintos, e esse documento supera outros que contêm `vitamin` e `recommend`. Os dois relevantes (MED-4573, sobre baixo status de vitamina D, e MED-4570, sobre doses de suplementos) não contêm `recommend` e aparecem nas posições 40 e 69. O semântico os coloca em 3º e 4º, ainda que seus dois primeiros documentos não sejam relevantes. A consulta fala da dificuldade de chegar a uma recomendação, enquanto os relevantes tratam de definição e dosagem, isto é, usam outro vocabulário, e a correspondência temática do semântico supera a lexical.

PLAIN-1537: “low-carb diets” (NDCG@10: BM25 0,095; semântico 0,662; diferença +0,567)

Tabela 8. PLAIN-1537: cinco primeiros documentos de cada sistema.

#	BM25	Score	Semântico	Similaridade
1	MED-4880	20,4429	MED-4515 (rel. 1)	0,6623
2	MED-2943	5,6980	MED-4880	0,6094
3	MED-1714	5,6204	MED-4514 (rel. 1)	0,5962
4	MED-4515 (rel. 1)	5,4694	MED-1616 (rel. 1)	0,5870
5	MED-2458	5,4607	MED-2586 (rel. 1)	0,5584

A consulta usa a abreviação “carb”, mas os títulos dos relevantes escrevem “carbohydrate”, que não coincide com `carb` após o stemming: MED-4515, o relevante mais bem colocado no BM25 (4º), casa apenas com `diet` e `low`. O primeiro documento (MED-4880) é o único que contém os três termos (score 20,4429, contra 5,6980 do segundo) e não é relevante; os demais, com scores entre 5,46 e 5,70, casam apenas com os termos genéricos `diet` e `low`, como MED-2458, sobre antioxidantes e asma. O BM25 coloca um relevante no Top-10, e o semântico, seis (a consulta tem 45 relevantes). No Top-5 do semântico, todos os títulos tratam de dietas pobres em carboidrato e quatro dos cinco documentos são relevantes, o que indica que o modelo reconheceu a abreviação como equivalente à forma completa.

Vantagem do lexical

PLAIN-1473: “kohlrabi” (NDCG@10: BM25 1,000; semântico 0,000; diferença $-1{,}000$)

Tabela 9. PLAIN-1473: cinco primeiros documentos de cada sistema.

#	BM25	Score	Semântico	Similaridade
1	MED-4455 (rel. 1)	11,6606	MED-3947	0,2202
2	MED-10	0,0000	MED-4660	0,2173
3	MED-1000	0,0000	MED-3441	0,2156
4	MED-1002	0,0000	MED-3447	0,2128
5	MED-1003	0,0000	MED-5024	0,2125

“Kohlrabi” é um termo raro e específico: apenas um documento da coleção o contém. Os demais itens do BM25 têm score zero e foram completados por ordem de identificador, sem nenhuma correspondência. Esse único documento é também o único relevante. No semântico, o relevante (MED-4455, sobre o conteúdo de glucorafanina em 59 cultivares de brássicas, com “kohlrabi” em uma lista de hortaliças no título) não aparece nem entre os 100 primeiros. Seus cinco primeiros documentos tratam de algas ou plantas sem relação com o tema, nenhum contém o termo, e as similaridades (0,2125 a 0,2202) são as mais baixas entre os seis casos. Os dados não revelam o mecanismo; uma hipótese é que o modelo represente mal um termo raro e que, em um documento sobre brássicas, a menção isolada pese pouco no embedding.

PLAIN-2081: “shelf life” (NDCG@10: BM25 1,000; semântico 0,000; diferença −1,000)

Tabela 10. PLAIN-2081: cinco primeiros documentos de cada sistema.

#	BM25	Score	Semântico	Similaridade
1	MED-4303 (rel. 1)	14,6784	MED-1378	0,4154
2	MED-1182	11,7916	MED-2422	0,3863
3	MED-2700	10,9258	MED-2510	0,3856
4	MED-2671	10,5192	MED-4715	0,3818
5	MED-2074	8,6999	MED-1433	0,3732

“Shelf life” é um termo técnico composto. Os cinco primeiros do BM25 contêm `shelf` e `life`, e o único documento relevante da consulta (MED-4303, sobre estabilidade oxidativa e shelf life de óleos) é o primeiro; os outros quatro também contêm os dois termos, tratam de outros alimentos e não têm julgamento positivo. O semântico coloca o relevante em 15º (similaridade de 0,3351), atrás de documentos sobre longevidade: MED-1378 (“Longevity and diet”), MED-2510 (extensão da vida por restrição alimentar) e MED-1433 (envelhecimento). Nenhum dos cinco contém `shelf`, o que sugere que `life` foi lido no sentido de duração da vida e não como parte do termo composto, caso de ambiguidade. Como há um único relevante, o NDCG@10 depende apenas de ele estar ou não entre os dez primeiros.

PLAIN-1288: “grapes” (NDCG@10: BM25 0,890; semântico 0,130; diferença −0,760)

Tabela 11. PLAIN-1288: cinco primeiros documentos de cada sistema.

#	BM25	Score	Semântico	Similaridade
1	MED-2668 (rel. 1)	9,4001	MED-3200	0,4264
2	MED-2669 (rel. 1)	9,1852	MED-3207	0,4250
3	MED-2083	8,9446	MED-398	0,4250
4	MED-1538 (rel. 1)	8,9387	MED-3210	0,4243
5	MED-5065 (rel. 1)	8,7301	MED-2083	0,4141

A consulta é um único termo específico. Após o stemming, “grapes” e “grape” coincidem, e apenas 29 documentos da coleção contêm `grape`, dos quais 15 são relevantes, todos entre as 27 primeiras posições do BM25; quatro dos cinco primeiros são relevantes. O semântico coloca nas quatro primeiras posições documentos sobre grapefruit (toranja), dois deles com o mesmo título (MED-3207 e MED-398), sem o termo `grape`, e seu primeiro relevante surge apenas em 9º. Os dados mostram que o modelo aproximou “grapes” de “grapefruit”, mas não indicam o mecanismo. Com 196 relevantes na consulta, o NDCG@10 do BM25 é alto, e seu Recall@10 é de apenas 0,046.

Síntese. Nos seis casos, o BM25 se sobressai quando a consulta é um termo específico (kohlrabi, grapes) ou composto técnico (shelf life), em que a correspondência exata é o sinal decisivo. O semântico se sobressai quando a consulta é uma frase em linguagem natural (PLAIN-307 e PLAIN-3085) ou usa uma variação do vocabulário dos documentos (carb e carbohydrate). O BM25 é enganado por termos incidentais e pelo stemming (shed e light; arriv), e o semântico confunde termos próximos (grapes e grapefruit) e tem dificuldade com termos raros. Como cada sistema vence em 107 consultas, eles parecem complementares, o que motiva a fusão da seção 4.3. Essas observações se limitam aos seis casos extremos analisados.

4.2 Tolerância a erros

A configuração congelada no desenvolvimento (trigramas, Jaccard $\geq 0{,}30$, distância ≤ 2) foi aplicada às 10 consultas do teste, com o protocolo da seção 3.5.

Tabela 12. Experimento de erros ortográficos nas 10 consultas de teste.

PLAIN-	Erro	Termo	Com erro	Corrigido	NDCG orig.	NDCG erro	NDCG corr.	Recup.
1018	inserção	dha	bdha	bha	0,521	0,000	0,000	0,00
102	remoção	childhood	hildhood	childhood	0,125	0,000	0,125	1,00
1039	substituição	domoic	aomoic	domoic	1,000	0,000	1,000	1,00
1088	troca de ordem	ecmo	cemo	chemo	0,553	0,000	0,000	0,00
1109	inserção	disruptors	adisruptors	disruptors	0,469	0,668	0,469	n/a
112	remoção	adhd	dhd	adhd	0,403	0,141	0,403	1,00
1130	substituição	ergothioneine	argothioneine	ergothioneine	1,000	0,000	1,000	1,00
1141	troca de ordem	evidence	veidence	evidence	0,220	0,139	0,220	1,00
1151	inserção	practices	apractices	practices	0,571	0,780	0,571	n/a
1172	remoção	fenugreek	enugreek	fenugreek	0,220	0,000	0,220	1,00
Média					**0,508**	**0,173**	**0,401**	**0,75**

n/a: o erro não reduziu o desempenho; a média de recuperação considera as 8 consultas restantes.

A correção recuperou em média 75% do desempenho perdido: seis consultas tiveram recuperação completa e duas, nula. Nos dois casos n/a, o BM25 ignora o termo inexistente e ranqueia pelos demais, e o NDCG@10 chegou a subir. As duas falhas são siglas curtas, em que outro termo do dicionário ficou mais próximo que o original: "dha" empatou com "bha" em distância e em Jaccard e perdeu no desempate alfabético, e "ecmo" ficou a duas edições de "cemo" e abaixo do limiar de Jaccard, enquanto "chemo" ficou a uma.

4.3 Busca híbrida

Ajuste do parâmetro k do RRF no conjunto de desenvolvimento (324 consultas):

Tabela 13. NDCG@10 médio no desenvolvimento para cada valor de k do RRF.

k	NDCG@10 (dev)
10	**0,3246**
60	0,3187
100	0,3193

O valor $k = 10$ foi escolhido e mantido na avaliação final. Valores menores de k dão mais peso às primeiras posições de cada ranking, o que favorece documentos bem colocados em um dos sistemas. As diferenças entre os três valores são pequenas (no máximo 0,006), de modo que o resultado é pouco sensível a k nessa faixa.

Na avaliação sobre o conjunto de teste (323 consultas), o híbrido supera os dois sistemas isolados em todas as métricas.

Tabela 14. Desempenho no conjunto de teste (323 consultas): sistemas isolados e híbrido.

Sistema	P@10	R@10	MAP@10	NDCG@10
Lexical (BM25)	0,2390	0,1532	0,1218	0,3278
Semântico	0,2433	0,1550	0,1108	0,3167
Híbrido (RRF, $k = 10$)	**0,2567**	**0,1698**	**0,1326**	**0,3505**

O ganho de NDCG@10 do híbrido é de +0,023 sobre o BM25 e de +0,034 sobre o semântico. Por consulta, o híbrido vence o BM25 em 116 consultas, perde em 72 e empata em 135; contra o semântico, vence em 128, perde em 76 e empata em 119. Os intervalos de confiança de 95% por bootstrap pareado (10.000 reamostragens) para a diferença média de NDCG@10 são de +0,011 a +0,035 contra o BM25 e de +0,019 a +0,050 contra o semântico, ambos acima de zero. Isso é coerente com a complementaridade observada na seção 4.1: o BM25 acerta consultas de termos específicos e o semântico, consultas em linguagem natural, e a fusão aproveita as duas fontes de evidência. O ganho é modesto em valor absoluto, e a fusão não recupera os casos em que apenas um dos sistemas encontra o relevante e o outro o coloca em posição muito baixa.

4.4 Reranking

Dos 16.150 pares pontuados no teste (323 consultas $\times$ 50 documentos), 1.537 (9,5%) excederam o limite de 512 tokens do cross-encoder e foram truncados, com o maior par chegando a 2.389 tokens antes do truncamento. O truncamento é bem menos frequente que no bi-encoder (78,8% dos documentos, com limite de 256 tokens), mas o conteúdo além de 512 tokens não influencia o score.

Resultados no conjunto de teste (323 consultas); os tempos médios por consulta, medidos em GPU (NVIDIA RTX 4050 Laptop), estão na seção 4.5:

Tabela 15. Desempenho no conjunto de teste (323 consultas), incluindo o reranking.

Sistema	**P@10**	**R@10**	**MAP@10**	**NDCG@10**
Lexical (BM25)	0,2390	0,1532	0,1218	0,3278
Semântico	0,2433	0,1550	0,1108	0,3167
Híbrido (RRF, $k = 10$)	**0,2567**	**0,1698**	0,1326	0,3505
Híbrido + reranking	0,2511	0,1666	**0,1388**	**0,3564**

O reranking melhora o MAP@10 (+0,006) e o NDCG@10 (+0,006), mas reduz ligeiramente P@10 e R@10. Isso é esperado, pois o reranking apenas reordena os mesmos 50 candidatos: ele pode aproximar relevantes do topo, o que beneficia as métricas sensíveis à posição, mas não acrescenta relevantes ao Top-10 e pode retirar alguns. A diferença média de NDCG@10 é pequena: o reranking vence o híbrido em 106 consultas, perde em 92 e empata em 125, e o intervalo de confiança de 95% por bootstrap pareado (10.000 reamostragens) para a diferença média é de $-0{,}005$ a +0,017, que inclui o zero. Assim, o ganho do reranking é pequeno e não é estatisticamente distinguível.

Análise por consulta

Os casos foram selecionados pela diferença de NDCG@10 entre o reranking e o híbrido no conjunto de teste. Nas tabelas, "rel. n" indica documento relevante com grau n nos qrels, e as posições referem-se ao ranking híbrido e ao ranking após o reranking.

Maiores ganhos

PLAIN-1320: “Harvard Physicians’ Study II” (NDCG@10: híbrido 0,000; reranking 0,562; diferença +0,562)

Tabela 16. PLAIN-1320: posição dos documentos antes e depois do reranking.

Documento	Título	Híbrido	Reranking
MED-2760 (rel. 1)	Multivitamins in the Prevention of Cancer in Men: The Physicians’ Health Study II…	11	1
MED-4929	Vitamins E and C in the Prevention of Cardiovascular Disease in Men: The Physicians’ Health Study II…	7	2
MED-2758 (rel. 1)	Multivitamins in the Prevention of Cardiovascular Disease in Men: The Physicians’ Health Study II…	12	3
MED-2761 (rel. 1)	Who uses multivitamins? A cross-sectional study in the Physicians’ Health Study	19	6
MED-2112	How evidence-based medicine biases physicians against nutrition	1	28
MED-1053	Physician disclosure of healthy personal behaviors improves credibility…	2	16

O Top-10 híbrido não continha nenhum relevante e era dominado por documentos sobre médicos em geral (aconselhamento nutricional, comportamento de médicos), que casam com “physicians” mas não com o estudo. Os três relevantes, que citam “Physicians’ Health Study” no título, estavam nas posições 11, 12 e 19 e passaram para 1, 3 e 6. O cross-encoder também promoveu MED-4929 (7 para 2) e MED-5124 (47 para 8), que citam o mesmo estudo no título, mas não têm julgamento positivo. A provável razão é que o modelo reconhece o nome do estudo como uma expressão, e não apenas a palavra “physicians”, e por isso rebaixa os documentos sobre médicos em geral (MED-2112 de 1 para 28, MED-1053 de 2 para 16).

PLAIN-1473: “kohlrabi” (NDCG@10: híbrido 0,631; reranking 1,000; diferença +0,369)

Tabela 17. PLAIN-1473: posição dos documentos antes e depois do reranking.

Documento	Título	Híbrido	Reranking
MED-4455 (rel. 1)	Glucoraphanin and 4-hydroxyglucobrassicin contents in seeds of 59 cultivars of broccoli…	2	1
MED-3947	Hibiscus anthocyanins rich extract-induced apoptotic cell death…	1	13

O único relevante (MED-4455) estava em 2º no híbrido, atrás de MED-3947 (sobre hibisco, sem relação com a consulta). Os dois tinham o mesmo score RRF (0,0909), pois cada um aparecia em 1º em um dos rankings de origem, e o desempate pelo identificador favoreceu MED-3947. O cross-encoder deu a MED-4455 o único score positivo do Top-10 (1,22; o segundo colocado tem $-4{,}31$) e rebaixou MED-3947 para 13º. Aqui o ganho decorre de o relevante receber um score claramente superior, e não de uma reordenação ampla: o restante do Top-10 reranqueado é formado por documentos sem relação evidente com a consulta, todos com scores negativos.

Pouca ou nenhuma alteração

PLAIN-1557: “magnesium” (NDCG@10: híbrido 0,315; reranking 0,315; diferença 0,000)

Tabela 18. PLAIN-1557: posição dos documentos antes e depois do reranking.

Documento	Título	Híbrido	Reranking
MED-3918 (rel. 1)	Herbal infusions as a source of calcium, magnesium, iron, zinc and copper…	3	2
MED-4315 (rel. 1)	Differences in metal content of the heart muscle in death from ischemic heart disease	2	3
MED-5005	Increased prevalence of constipation in pre-school children…	11	5
MED-3497	Evaluation of certain food additives and contaminants	27	7
MED-1110	The potential role of curcumin in patients with monoclonal gammopathy…	5	30
MED-1843	Aluminium in over-the-counter drugs: risks outweigh benefits?	8	34

Oito documentos mudaram de posição, mas o NDCG@10 não se alterou porque os relevantes apenas trocaram de lugar entre si (MED-4315 e MED-3918, em 2º e 3º, ambos de grau 1) e MED-4313 permaneceu em 9º. Os documentos que entraram no Top-10 (MED-5005, MED-3497, MED-2249) e os que saíram (MED-1110, MED-1844, MED-1843) não têm julgamento positivo, de modo que a troca ocorreu entre não relevantes. Os três que saíram (curcumina, alumínio e metais em medicamentos) não mencionam magnésio em nenhuma passagem do texto, enquanto os três que entraram o mencionam (duas vezes em MED-5005 e uma em MED-3497 e MED-2249). A alteração é, portanto, coerente com o cross-encoder priorizando documentos que tratam do termo da consulta, ainda que como assunto secundário.

Maior piora

PLAIN-2540: “Does Cholesterol Size Matter?” (NDCG@10: híbrido 0,615; reranking 0,303; diferença $-0{,}312$)

Tabela 19. PLAIN-2540: posição dos documentos antes e depois do reranking.

Documento	Título	Híbrido	Reranking
MED-1890 (rel. 2)	Dietary cholesterol from eggs increases the ratio of total cholesterol to high-density…	1	15
MED-1885 (rel. 2)	Rethinking dietary cholesterol	10	12
MED-1886 (rel. 2)	Lipoprotein Particle Profiles by Nuclear Magnetic Resonance Compared with Standard Lipid…	2	2
MED-1882 (rel. 2)	Low-density lipoprotein and high-density lipoprotein particle subclasses predict coronary…	6	8
MED-1205	Effect of cholesterol crystals on plaques and intima in arteries of patients with acute…	21	1
MED-1968	Effects of increasing amounts of dietary cholesterol on postprandial lipemia…	17	3

O número de relevantes no Top-10 caiu de cinco para três: MED-1890, que era o 1º, foi para 15º e MED-1885 saiu do Top-10 (de 10º para 12º). Os documentos que subiram (MED-1205, MED-1968, MED-3398) tratam de colesterol, mas não têm julgamento positivo. Os dois relevantes que permaneceram bem colocados, MED-1886 e MED-1882, têm “particle” no título. Já MED-1890 e MED-1885 não mencionam “size” nem “particle”, no texto, enquanto MED-1882 menciona “size” 3 vezes e “particle” 11. A perda se concentra, assim, em relevantes que tratam de colesterol da dieta e não do tamanho das partículas, aspecto que o título da consulta destaca.

Entre os que subiram, apenas MED-1205 menciona “size” (uma vez); os demais (MED-1968, MED-3398) tratam de colesterol em geral, sem julgamento positivo. Todos os scores do Top-10 reranqueado são negativos (o maior é $-3{,}13$), isto é, o modelo não atribuiu alta relevância a nenhum documento.

4.5 Tempos

Tempos médios por consulta nas 323 consultas de teste (0,0008 s para o BM25 nas consultas de desenvolvimento), medidos na máquina descrita na seção 3.4:

Tabela 20. Tempos médios por etapa.

Etapa	**Tempo**
Construção do índice invertido (tokenização, pré-processamento, posting lists e comprimentos; sem leitura dos arquivos)	5,3003 s
Geração dos embeddings dos 3.633 documentos (GPU)	9,27 s
Consulta lexical (BM25, top-100)	0,0006 s
Consulta semântica (codificação e busca, top-100)	0,0185 s
Consulta híbrida	0,0171 s
Consulta híbrida + reranking	0,2614 s

O índice construído tem 19.054 termos e 360.200 postings, com comprimento médio de 165,82 termos por documento. No sistema com reranking, 0,0164 s correspondem à recuperação híbrida e 0,2439 s ao cross-encoder, de modo que o reranking multiplica por cerca de 15 o tempo do híbrido. O reranking, cujo ganho de NDCG@10 não é estatisticamente distinguível (seção 4.4), é a etapa mais cara do pipeline de recuperação.

4.6 RAG

Recuperação. As métricas usam os cinco documentos enviados à LLM nas dez consultas do experimento.

Tabela 21. Métricas de recuperação sobre os cinco documentos enviados à LLM.

PLAIN-	Relevantes no contexto	Total de relevantes	P@5	R@5	Hit@5
68	1	55	0,20	0,0182	1
2450	2	38	0,40	0,0526	1
153	5	47	1,00	0,1064	1
2850	0	9	0,00	0,0000	0
2750	4	59	0,80	0,0678	1
270	2	52	0,40	0,0385	1
2470	3	73	0,60	0,0411	1
2430	3	46	0,60	0,0652	1
238	1	54	0,20	0,0185	1
3342	2	3	0,40	0,6667	1
Média			**0,46**	**0,1075**	**0,90**

Nove das dez consultas receberam ao menos um documento relevante. A exceção é PLAIN-2850, em que nenhum dos cinco documentos tem julgamento positivo; decidimos manter a consulta para analisar como se comporta esse tipo de caso. O Recall@5 é baixo porque o corte é de cinco documentos e as consultas têm de 3 a 73 relevantes, e PLAIN-3342, com apenas 3, tem o maior valor (0,6667).

Geração. Médias das notas (0 a 2) por avaliador e das duas pessoas:

Tabela 22. Notas médias (0 a 2) por avaliador e das duas pessoas.

Critério	Pessoa 1 sem RAG	Pessoa 1 com RAG	Pessoa 2 sem RAG	Pessoa 2 com RAG	Média sem RAG	Média com RAG
Fidelidade	0,60	1,50	0,40	1,20	0,50	1,35
Completude	0,90	1,60	0,70	1,20	0,80	1,40
Utilidade	0,90	1,40	0,90	1,40	0,90	1,40
Rastreabilidade	N/A	1,30	N/A	1,30	N/A	1,30

As duas pessoas atribuem médias maiores com RAG nos três critérios comuns, e a Fidelidade tem a maior diferença (+0,90 na Pessoa 1 e +0,80 na Pessoa 2). Por consulta, o RAG é melhor em nove e igual em PLAIN-2850, com ganho médio de 0,65 ponto. Sem RAG, as respostas contradizem os documentos em PLAIN-68 e PLAIN-2750, e quem lê não tem fonte para verificar as afirmações. Com RAG, há falhas mesmo com o documento no contexto, como em PLAIN-3342, e em seis das 11 notas de Rastreabilidade abaixo de 2 a fonte não foi identificada.

4.7 Análise de falhas ponta a ponta

Casos escolhidos segundo os critérios da seção 3.5 (médias das duas pessoas):

Tabela 23. Casos da análise de falhas ponta a ponta (médias das duas pessoas).

Caso	PLAIN-	Fidelidade sem RAG	Fidelidade com RAG	Completude sem RAG	Completude com RAG	Utilidade sem RAG	Utilidade com RAG	Rastreabilidade com RAG
Melhora clara	68	0,00	2,00	0,50	2,00	1,00	2,00	1,00
Pouca diferença	2450	1,00	1,00	1,00	1,50	1,00	1,00	0,50
RAG não ajudou	2850	0,00	0,00	0,00	0,00	0,00	0,00	1,00

Melhora clara: PLAIN-68, "What is Actually in Chicken Nuggets?" Sem RAG, a resposta descreve um nugget de peito de frango, e as duas pessoas deram Fidelidade 0. Com RAG, reproduz o resultado de MED-2991: o músculo não era o componente predominante, e a gordura aparecia em quantidade igual ou maior. A informação chegou ao contexto, pois MED-2991 (grau 2) ficou em 1º no lexical, no semântico, na fusão e no reranking.

Pouca diferença: PLAIN-2450, "Are Organic Foods Safer?" Só a Completude mudou, de 1,00 para 1,50. Sem RAG, a resposta se contradiz: diz que orgânicos podem ser mais seguros e conclui que não há evidência disso. Com RAG, abre com "Yes" e termina reconhecendo que a evidência é insuficiente. A informação chegou ao contexto, com os cinco documentos entre os dez primeiros do lexical e do semântico, e MED-1178 e MED-1179 trazem a ressalva ("The health benefits of organic foods are unclear"; "no well-powered human studies"). O "Yes" se apoia em MED-1144, um levantamento de percepção de risco. O problema está na geração. Uma hipótese é que o modelo tenha tratado como evidência os números de MED-1144 (50 e 200 mortes por milhão), que são estimativas dos compradores: dois dos três pontos da resposta se apoiam nesse documento, e as ressalvas de MED-1179 só aparecem no terceiro ponto.

RAG não ajudou: PLAIN-2850, "More Antibiotics In White Meat or Dark Meat?" As duas pessoas deram 0 em Fidelidade, Completude e Utilidade nas duas condições. Sem RAG, a resposta afirma que não há diferença entre os tipos de carne. Com RAG, usa MED-4983, um estudo de mortalidade sem relação com antibióticos. O documento que responde, MED-4166 (grau 2), mede concentrações maiores de enrofloxacina no peito do que na coxa de frangos e não chegou ao contexto.

A falha vem da recuperação, e não da geração com RAG. MED-4166 já estava fora do

Top-5 nos dois sistemas (34º no lexical e 14º no semântico), a fusão o manteve em 12º e o reranking o piorou para 19º, de modo que a seleção do Top-5 o deixou de fora. O único outro relevante que chegou ao Top-50 híbrido, MED-4167, ficou em 22º e subiu para 11º, também fora do contexto. MED-4166 tem zero ocorrências de "meat", "white" e "dark", termos da consulta, enquanto os cinco documentos enviados têm "meat" de 2 a 12 vezes. Uma hipótese é que a diferença de vocabulário (carne branca e escura contra peito e coxa) tenha favorecido esses textos. Sem RAG o estudo não está disponível, e com RAG não chega ao contexto.

5 Considerações finais

Os experimentos permitem as seguintes conclusões, todas restritas à coleção, aos modelos e às consultas avaliados.

1. **Lexical e semântico são equivalentes no agregado, mas complementares.** A diferença de NDCG@10 entre eles ($-0{,}011$; IC 95% de $-0{,}033$ a $+0{,}011$) não distingue um sistema do outro, e cada um vence em 107 consultas. O BM25 se sobressai em termos específicos e compostos técnicos (kohlrabi, grapes, shelf life); o bi-encoder, em frases em linguagem natural e variações de vocabulário (carb e carbohydrate). Cada um tem falhas características: o BM25 é enganado por termos incidentais e pelo stemming, e o bi-encoder confunde termos próximos e tem dificuldade com termos raros.
2. **A busca híbrida é a melhoria mais robusta.** O RRF com $k = 10$ eleva o NDCG@10 para 0,3505, com ganhos de +0,023 sobre o BM25 e de +0,034 sobre o semântico, e intervalos de confiança acima de zero. O ganho é modesto em valor absoluto, e o resultado é pouco sensível a k entre 10 e 100.
3. **O reranking trouxe ganho pequeno e custo alto em nossos testes.** O cross-encoder eleva o NDCG@10 para 0,3564 e o MAP@10 para 0,1388, mas reduz P@10 e R@10, e a diferença não é estatisticamente distinguível (IC de $-0{,}005$ a $+0{,}017$). O custo é cerca de 15 vezes o tempo do híbrido. Os casos mostram ganhos quando a consulta nomeia uma entidade ou expressão (Physicians' Health Study II) e piora quando ela destaca um aspecto específico que os relevantes não mencionam (tamanho das partículas de colesterol).
4. **A correção ortográfica recupera boa parte do desempenho perdido.** Com k-gramas, Jaccard e Levenshtein, a recuperação média foi de 75%. As falhas se concentram em siglas curtas, em que outro termo do dicionário fica mais próximo que o original.
5. **O RAG melhora fidelidade, completude e utilidade, mas depende da recuperação.** Pela avaliação humana, a Fidelidade média passou de 0,50 para 1,35, a Completude de 0,80 para 1,40 e a Utilidade de 0,90 para 1,40, e a Rastreabilidade com RAG foi de 1,30. A análise ponta a ponta mostra que a qualidade da resposta depende de a evidência chegar ao contexto: em PLAIN-2850, o documento relevante ficou fora dos cinco enviados e o RAG não ajudou. Mesmo com a evidência no contexto, a LLM pode se apoiar em documentos pouco adequados (PLAIN-2450).

6 Uso de ferramentas de IA

Foram utilizadas ferramentas de IA generativa (ChatGPT e Claude) como apoio em praticamente todas as etapas do trabalho: na escrita e depuração do código (pipeline de recuperação, métricas e notebook), na redação do relatório e na sua organização na estrutura final. As análises dos resultados foram compreendidas por todos os integrantes do grupo, que recorreram à IA apenas para reformular o texto de modo mais claro e adequado ao formato acadêmico. Os integrantes revisaram o código, a metodologia e os resultados e respondem por eles, de modo que o uso dessas ferramentas não substitui o entendimento do grupo sobre o que foi desenvolvido.

Referências

Boteva, V., Gholipour, D., Sokolov, A. e Riezler, S. (2016). A full-text learning to rank dataset for medical information retrieval. Em *Advances in Information Retrieval (ECIR 2016)*, volume 9626 de *LNCS*. Springer.

Cormack, G. V., Clarke, C. L. A. e Büttcher, S. (2009). Reciprocal rank fusion outperforms Condorcet and individual rank learning methods. Em *Proc. 32nd ACM SIGIR*, p. 758–759.

Lewis, P. et al. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. Em *Advances in Neural Information Processing Systems (NeurIPS)*, volume 33.

Manning, C. D., Raghavan, P. e Schütze, H. (2008). *Introduction to Information Retrieval*. Cambridge University Press.

Nogueira, R. e Cho, K. (2019). Passage re-ranking with BERT. *arXiv:1901.04085*.

Porter, M. F. (1980). An algorithm for suffix stripping. *Program*, 14(3):130–137.

Qwen Team (2024). Qwen2.5 technical report. *arXiv:2412.15115*.

Reimers, N. e Gurevych, I. (2019). Sentence-BERT: sentence embeddings using Siamese BERT-networks. Em *Proc. EMNLP-IJCNLP*, p. 3982–3992.

Robertson, S. e Zaragoza, H. (2009). The probabilistic relevance framework: BM25 and beyond. *Foundations and Trends in Information Retrieval*, 3(4):333–389.

Thakur, N., Reimers, N., Rücklé, A., Srivastava, A. e Gurevych, I. (2021). BEIR: a heterogeneous benchmark for zero-shot evaluation of information retrieval models. Em *NeurIPS Datasets and Benchmarks Track*.